SpeechFlow – innowacyjny program służący do analizy nagrań mowy

Opis koncepcji

Celem aplikacji ma być wspieranie użytkowników w poprawie dykcji, akcentu i innych elementów mowy, aby ich wypowiedzi były bardziej zrozumiałe i profesjonalne. Aplikacja mogłaby znaleźć potencjalne zastosowania w terapii logopedycznej, szkoleniach z wystąpień publicznych, nauce języków obcych, a także jako pomoc w poprawie mowy w zawodach wymagających wysokiej komunikatywności, takich jak aktor lub nauczyciel.

Program działałby w następujący sposób:

1. Użytkownik nagrywa swoją mowę
2. SpeechFlow przy pomocy modelu AI analizuje nagranie pod kątem dykcji, tempa, akcentu oraz wyraźności
3. Program dostarcza użytkownikowi raport z analizą i sugestiami jak poprawić swoją wymowę

Lista rzeczy potrzebnych do dalszego rozwoju:

1. Komputer
2. Dostęp do internetu
3. Serwer testowy
4. API modelu AI
5. Środowisko VS Code
6. Repozytorium GitHub

Poziom TLR 3

- **Moduł rejestracji nagrania -** pozyskiwanie sygnału audio z mikrofonu oraz jego wstępne przetwarzanie z wykorzystaniem

opracowanych filtrów cyfrowych. W ramach wskazanego modułu szczególny nacisk zostanie położony na poprawność (stabilność) wyciszania szumów otoczenia oraz normalizację poziomu głośności. Moduł będzie posiadał zaimplementowaną wersję algorytmu usuwania zakłóceń.

- **Moduł analizy fonetycznej -** rozpoznawanie i segmentacja pojedynczych głosek w strumieniu mowy z wykorzystaniem opracowanego algorytmu klasyfikacji fonetycznej, a także analiza podziału wypowiedzi na sylaby oraz ocena ich budowy fonetycznej pod kątem kompletności. W ramach wskazanego modułu szczególny nacisk zostanie położony na poprawność przypisania zarejestrowanych dźwięków do odpowiadających im wzorców fonetycznych.
- **Moduł generowania raportów zwrotnych -** agregacja podstawowych wskaźników nagrania i ich prezentacja w formie graficznej. Rolą modułu będzie czytelne przedstawienie wyników użytkownikowi, gdzie szczególny nacisk zostanie położony na prostotę interpretacji uzyskanych danych.

Poziom TLR 4. Weryfikacja koncepcji w warunkach laboratoryjnych

- **Moduł rejestracji nagrania** - przygotowano zestaw kontrolny 100 próbkowych nagrań audio w formatach: wav, mp3, zarejestrowanych w środowiskach o różnym natężeniu hałasu. Wykonano 100 serii testów filtracji szumów oraz normalizacji głośności na zestawie kontrolnym. Algorytm wykazał pewne odchylenia w poziomach głośności przy nagraniach o skrajnie niskim poziomie sygnału wejściowego. Ustalono, że na wynik ma wpływ niewłaściwy dobór stałej czasowej w podsystemie automatycznej regulacji wzmocnienia (AGC). Wprowadzono poprawkę do algorytmu i ponownie wykonano 100 serii testów. Wyniki w całej serii były stabilne, a zniekształcenia sygnału zostały zminimalizowane.

- **Moduł analizy fonetycznej** - przygotowano zestaw kontrolny 100 wypowiedzi wzorcowych zawierających pełny repertuar fonemów języka polskiego oraz zróżnicowaną strukturę sylabową. Określono, że jednostkami wyjściowymi klasyfikacji będą etykiety zgodne ze standardem SAMPA dla języka polskiego. Wykonano 100 serii testów rozpoznawania głosek oraz segmentacji sylabowej na zestawie kontrolnym. Algorytm wykazał pewne odchylenie, myląc granice sylab w miejscach zbiegu spółgłosek trących. Ustalono, że na wynik ma wpływ zbyt szerokie okno analizy widmowej w algorytmie wykrywania przejść energetycznych. Wprowadzono poprawkę do algorytmu i ponownie wykonano 100 serii testów. Wyznaczenie granic głosek i sylab stało się powtarzalne, a błąd segmentacji został zminimalizowany.
- **Moduł generowania raportów zwrotnych** - przygotowano zestaw kontrolny 100 gotowych struktur danych zawierających zagregowane metryki mowy (tempo, pauzy, fonemy, głośność). Określono, że wyjściowym formatem generowanego raportu graficznego będzie struktura JSON przekazywana do szablonu widoku. Wykonano 100 serii testów generowania podsumowań graficznych na zestawie kontrolnym. Algorytm wykazał pewne odchylenie w czasie renderowania wykresów dla bardzo długich nagrań. Ustalono, że na wynik ma wpływ zbyt wysoka rozdzielczość danych wejściowych przekazywanych do komponentu rysującego. Wprowadzono poprawkę do algorytmu w postaci wstępnej redukcji punktów pomiarowych i ponownie wykonano 100 serii testów. Czas generowania widoku we wszystkich próbach był porównywalny, a opóźnienia zostały zminimalizowane.

Określenie ryzyk dla TLR 4 i sposoby ich eliminacji

1. **Ryzyko (szansa 45%):** Użytkownik nagrywa mowę ze zbyt dużej odległości lub szeptem
   Rozwiązanie: Wdrożenie automatycznego testu głośności przed rozpoczęciem analizy. Jeśli poziom sygnału jest zbyt niski,

aplikacja natychmiast wyświetla prosty komunikat z prośbą o zbliżenie się do mikrofonu lub głośniejszy śpiew/mowę, uniemożliwiając analizę nagrania złej jakości.

2. **Ryzyko (szansa 35%):** Wolna praca modułu analizy fonetycznej przy bardzo długich nagraniach
   Rozwiązanie: Wprowadzenie limitu długości pojedynczej próby (np. maksymalnie 60 sekund) lub automatyczny podział długiego pliku na krótsze kilkusekundowe fragmenty przetwarzane kolejno w tle.